Reducción de dimensionalidad mediante FSCNCA y Forward Selection

Aylin Lucero Parra Castellanos
U00182373

Entregado a:
Carlos Julio Arizmendi Pereira

Universidad Autónoma de Bucaramanga
Facultad de Ingeniería
Ingeniería Biomédica
24 de octubre del 2026

ntroducción

La reducción de dimensionalidad es una técnica que permite disminuir el número de características utilizadas en un problema de clasificación, procurando conservar la información relevante para distinguir las clases. En este laboratorio se comparan dos métodos de selección de características: Feature Selection using Neighborhood Component Analysis (FSCNCA) y Forward Selection. Para evaluar los subconjuntos de variables se utiliza un reconocedor euclídeo basado en la distancia mínima entre cada patrón y los centroides de las clases.

FSCNCA asigna pesos a las variables predictoras y permite ordenarlas según su relevancia para la clasificación. Su desempeño depende del parámetro de regularización lambda, por lo que se evalúan diferentes valores utilizando el conjunto de validación. Forward Selection incorpora variables progresivamente y evalúa el desempeño alcanzado en cada paso para identificar un subconjunto adecuado.

Adicionalmente, el análisis de componentes principales (PCA) permite representar los datos en un espacio de menor dimensión y observar su distribución. La comparación entre las proyecciones originales y las obtenidas después de la selección de características permite estudiar los cambios en la estructura visual de las clases.

El laboratorio también contempla 150 ejecuciones independientes para analizar la variabilidad de las métricas. La selección de variables y modelos debe realizarse con información de entrenamiento y validación, mientras que el conjunto de prueba debe reservarse para la evaluación final.

Objetivos

Objetivo general

Aplicar y comparar FSCNCA y Forward Selection para reducir la dimensionalidad de una base de datos de clasificación, utilizando un reconocedor euclídeo y analizando el desempeño de los modelos mediante entrenamiento, validación y prueba.

Objetivos específicos

- Caracterizar la base de datos, las variables predictoras y la distribución de las clases.
- Evaluar diferentes valores de lambda para FSCNCA mediante el accuracy de validación.
- Identificar las variables más relevantes mediante FSCNCA y Forward Selection.

- Analizar el comportamiento del accuracy y la sensibilidad a medida que cambia el número de variables.
- Comparar el modelo de referencia con los modelos que utilizan características seleccionadas.
- Analizar los resultados de las 150 ejecuciones mediante el promedio y la desviación estándar.
- Examinar mediante PCA la distribución de los datos antes y después de la selección de características.

Preparación de la base de datos

La base de datos utilizada contiene 650 registros y 30 variables predictoras. La variable objetivo, denominada class, presenta dos categorías: negativo y positivo.

Tabla 1. Características generales de la base de datos.

Característica	Resultado
Registros totales	650
Variables predictoras	30
Casos negativos	482
Casos positivos	168
Valores faltantes en las variables predictoras	0

La distribución de clases es desigual: aproximadamente el 74,15 % de los registros corresponde a la clase negativa y el 25,85 % a la positiva. Este desbalance debe tenerse en cuenta al interpretar las métricas, debido a que un modelo puede obtener un accuracy relativamente alto sin identificar correctamente una proporción suficiente de casos positivos.

En una partición documentada durante el desarrollo se utilizaron 454 registros para entrenamiento, 98 para validación y 98 para prueba. Estos tamaños suman 650 registros. En las ejecuciones repetidas, los registros asignados a cada conjunto cambian según la partición generada.

La normalización debe ajustarse exclusivamente con los datos de entrenamiento de cada ejecución y aplicarse posteriormente a validación y prueba. Asimismo, la misma partición debe utilizarse para comparar los tres escenarios: todas las variables, selección mediante FSCNCA y selección mediante Forward Selection.

Reconocedor euclídeo con todas las variables

El reconocedor euclídeo clasifica cada patrón según la menor distancia euclídea entre sus características y los centroides calculados para las clases con los datos de entrenamiento.

En la evaluación individual compartida se obtuvo un accuracy de validación de 57,14 %, correspondiente a 56 predicciones correctas de 98 registros.

Tabla 2. Evaluación inicial del reconocedor euclídeo con todas las variables.

Indicador	Resultado
Variables utilizadas	30
Registros de validación	98
Predicciones correctas	56
Predicciones incorrectas	42
Accuracy de validación	57,14 %

Este resultado corresponde a una evaluación individual y no al promedio de las 150 ejecuciones. Por tanto, se utiliza como referencia preliminar.

Selección de características mediante FSCNCA

Sintonización del parámetro lambda

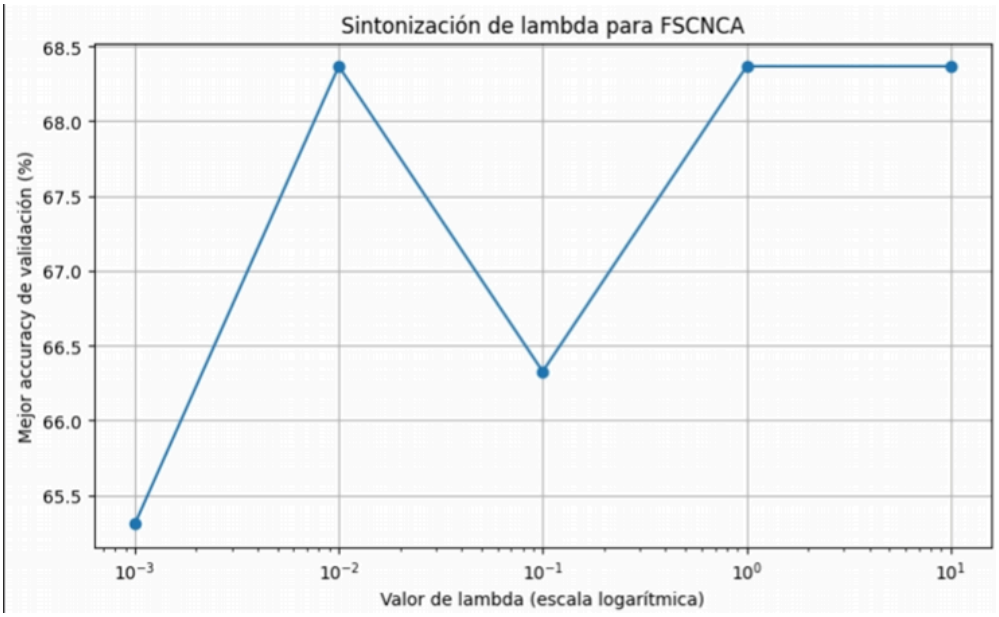
Se evaluaron los valores de lambda 0,001; 0,01; 0,1; 1 y 10. Para cada valor se registraron la cantidad de variables asociada al mejor resultado y el accuracy de validación.

Tabla 3. Sintonización de lambda para FSCNCA.

Lambda	Cantidad de variables	Accuracy de validación
0,001	4	65,31 %
0,01	18	68,37 %
0,1	9	66,33 %
1	18	68,37 %
10	18	68,37 %

Los resultados muestran que el máximo accuracy observado fue 68,37 %, alcanzado con lambda igual a 0,01, 1 y 10. En la ejecución compartida se seleccionó lambda = 0,01, que corresponde a una de las configuraciones empatadas en el máximo.

Figura 1. Sintonización de lambda para FSCNCA.



La gráfica permite observar que el desempeño varía con el parámetro de regularización. La elección de lambda debe documentarse utilizando el criterio definido para la selección y sin consultar el conjunto de prueba.

Pesos asignados a las variables

FSCNCA asignó pesos a las 30 variables predictoras. La siguiente tabla reproduce los valores de la hoja Pesos_FSCNCA del archivo Resultados_Seleccion_Variables.xlsx.

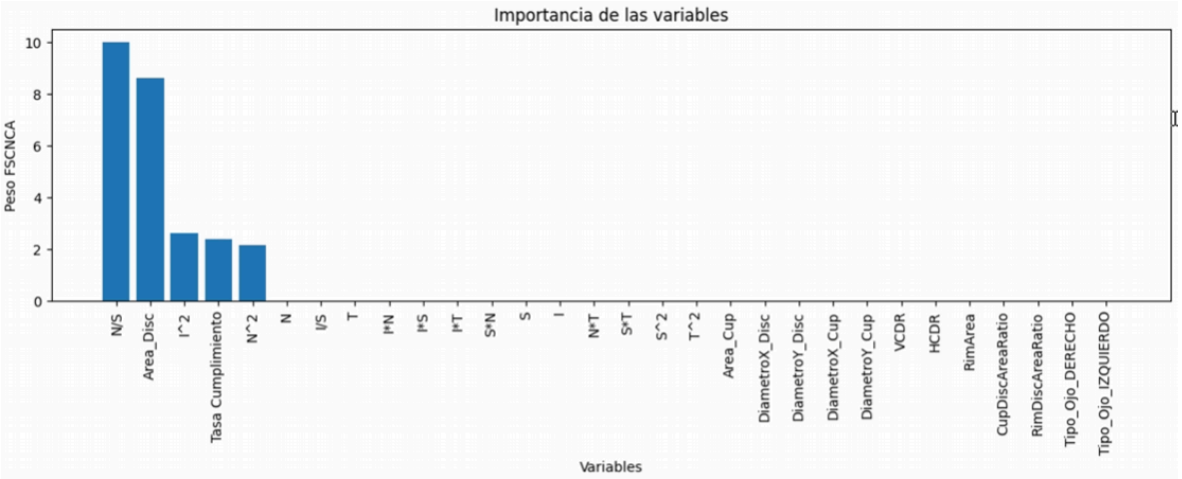
Tabla 4. Pesos de las variables según FSCNCA.

Variable	Peso
N/S	10,000000
Area_Disc	8,641055
I^2	2,636035
Tasa Cumplimiento	2,416079

N^2	2,179792
N	0,000000
I/S	0,000000
T	0,000000
I*N	0,000000
I*S	0,000000
I*T	0,000000
S*N	0,000000
S	0,000000
I	0,000000
N*T	0,000000
S*T	0,000000
S^2	0,000000
T^2	0,000000
T^2	0,000000

Area_Cup	0,000000
DiametroX_Disc	0,000000
DiametroY_Disc	0,000000
DiametroX_Cup	0,000000
DiametroY_Cup	0,000000
VCDR	0,000000
HCDR	0,000000
RimArea	0,000000
CupDiscAreaRatio	0,000000
RimDiscAreaRatio	0,000000
Tipo_Ojo_DERECHO	0,000000
Tipo_Ojo_IZQUIERDO	0,000000

Figura 2. Importancia de las variables según FSCNCA.



Los mayores pesos se asignaron a N/S y Area_Disc. Las variables I^2, Tasa Cumplimiento y N^2 también presentaron pesos positivos, aunque menores. Esto muestra que FSCNCA concentró la importancia en un grupo reducido de características en la ejecución representada. Un peso alto no implica por sí solo causalidad ni garantiza una clasificación correcta.

Evaluación según el número de variables

La hoja Evaluacion_FSCNCA contiene 30 combinaciones, correspondientes a diferentes cantidades de variables. En los resultados compartidos, el accuracy máximo observado fue 68,37 % con 18 variables.

Tabla 5. Resumen de los resultados de FSCNCA.

Cantidad de variables	Accuracy de validación	Sensibilidad
1	64,29 %	40 %
7	65,31 %	48 %
8	66,33 %	44 %
12	66,33 %	44 %

17	66,33 %	44 %
18	68,37 %	44 %
29	61,22 %	56 %
30	57,14 %	64 %

La tabla muestra una selección representativa de filas. Para la entrega, debe adjuntarse o incorporarse la tabla completa de 30 filas exportada desde el Excel, porque la guía solicita los resultados de la curva según el número de características.

El accuracy más alto observado se obtuvo con 18 variables. Al utilizar las 30 variables, el accuracy descendió a 57,14 %, mientras que la sensibilidad aumentó a 64 %. Esto ilustra que reducir el número de variables puede modificar el equilibrio entre los aciertos globales y la identificación de casos positivos.

Variables seleccionadas mediante FSCNCA

El archivo Variables_seleccionadas_FSCNCA.xlsx contiene 18 variables seleccionadas.

Tabla 6. Variables seleccionadas mediante FSCNCA.

Orden	Variable
1	N/S
2	Area_Disc
3	I^2
4	Tasa Cumplimiento

5 N^2

6 N

7 I/S

8 T

9 I*N

10 I*S

11 I*T

12 S*N

13 S

14 I

15 N*T

16 S*T

17 S^2

18 T^2

Selección de características mediante Forward Selection

Forward Selection agrega progresivamente variables y evalúa el desempeño del reconocedor euclídeo en cada paso. El archivo Resultados_Seleccion_Variables.xlsx, hoja Forward_Selection, contiene 30 filas con la variable agregada, el accuracy y la sensibilidad.

Tabla 7. Resultados representativos de Forward Selection.

Cantidad de variables	Variable agregada	Accuracy	Sensibilidad
1	VCDR	75,51 %	12 %
2	CupDiscAreaRatio	75,51 %	4 %
3	S*T	76,53 %	8 %
4	DiametroY_Cup	75,51 %	4 %
5	RimDiscAreaRatio	75,51 %	4 %
6	I*T	76,53 %	8 %
7	S^2	76,53 %	8 %
8	I	75,51 %	4 %
9	N	75,51 %	4 %
10	I*S	75,51 %	4 %
11	I^2	75,51 %	12 %

12	HCDR	77,55 %	16 %
18	T	73,47 %	12 %
22	N/S	65,31 %	24 %
23	Tasa Cumplimiento	64,29 %	32 %
26	Area_Disc	66,33 %	44 %
28	Area_Cup	63,27 %	48 %
29	Tipo_Ojo_DERECHO	61,22 %	56 %
30	Tipo_Ojo_IZQUIERDO	57,14 %	64 %

La tabla anterior muestra filas representativas. Debe acompañarse con la tabla completa de 30 filas exportada desde el Excel.

Mejor configuración observada

La tabla individual de Forward Selection muestra un accuracy máximo de 77,55 % con 12 variables y sensibilidad de 16 %.

Tabla 8. Variables seleccionadas por Forward Selection en la configuración de 12 variables.

Orden	Variable
1	VCDR
2	CupDiscAreaRatio

3 S*T

4 DiametroY_Cup

5 RimDiscAreaRatio

6 I*T

7 S^2

8 I

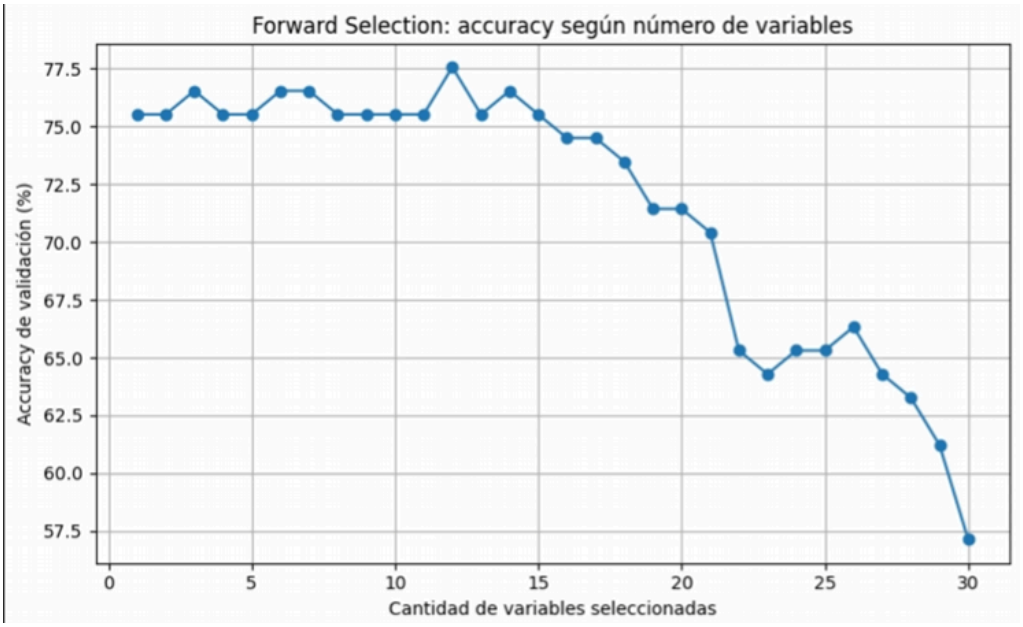
9 N

10 I*S

11 I^2

12 HCDR

Figura 5. Accuracy de validación según el número de variables de Forward Selection.



La curva muestra que el accuracy alcanza su máximo observado con 12 variables y disminuye en varios pasos posteriores. En cambio, la sensibilidad aumenta hacia los últimos pasos. Esto demuestra que la cantidad de variables seleccionadas influye en el equilibrio entre las métricas.

Resultados de las 150 ejecuciones

El archivo Resultados_150_Ejecuciones(1).xlsx contiene la hoja Resultados_por_ejecucion, con 150 filas, y la hoja Promedio_y_desviacion, con los estadísticos resumidos de FSCNCA y Forward Selection.

Tabla 9. Promedio y desviación estándar de los resultados disponibles.

Métrica	FSCNCA: promedio	FSCNCA: desviación estándar	Forward Selection: promedio	Forward Selection: desviación estándar
Cantidad de variables	9,740	9,473	2,033	2,390

Accuracy	63,97 %	4,69 puntos porcentuales	42,73 %	10,91 puntos porcentuales
Sensibilidad	56,27 %	11,63 puntos porcentuales	80,43 %	9,24 puntos porcentuales

La desviación estándar de las métricas originales está expresada como proporción en el Excel; en la tabla se ha convertido a puntos porcentuales para facilitar la interpretación.

Interpretación de los resultados

FSCNCA presentó un accuracy promedio de 63,97 %, superior al 42,73 % registrado para Forward Selection. Además, la desviación estándar del accuracy de FSCNCA fue de 4,69 puntos porcentuales, mientras que la de Forward Selection fue de 10,91 puntos porcentuales. En el resumen disponible, FSCNCA mostró mayor estabilidad en accuracy.

Forward Selection obtuvo una sensibilidad promedio de 80,43 %, superior al 56,27 % de FSCNCA. Esto indica que identificó una mayor proporción de casos positivos en las evaluaciones resumidas, aunque su proporción de aciertos globales fue menor.

El número promedio de variables fue de 9,74 para FSCNCA y de 2,03 para Forward Selection. Estos valores corresponden al promedio de las cantidades registradas por repetición y no deben confundirse con las 18 y 12 variables seleccionadas en las evaluaciones individuales anteriores.

Comparación de métodos

Los resultados individuales y los promedios de las 150 ejecuciones deben interpretarse por separado.

Tabla 10. Comparación de resultados disponibles.

Criterio	FSCNCA	Forward Selection

Máximo accuracy observado en evaluación individual	68,37 % con 18 variables	77,55 % con 12 variables
Accuracy promedio del archivo de 150 ejecuciones	63,97 %	42,73 %
Desviación estándar del accuracy	4,69 puntos porcentuales	10,91 puntos porcentuales
Sensibilidad promedio	56,27 %	80,43 %
Número promedio de variables	9,74	2,03

FSCNCA mostró un mayor accuracy promedio y menor variabilidad del accuracy en el resumen disponible. Forward Selection presentó una mayor sensibilidad promedio y un número promedio menor de variables.

No obstante, el máximo de una evaluación individual no debe compararse directamente con el promedio de 150 ejecuciones como si fueran la misma medida. La comparación definitiva debe utilizar las mismas particiones, las mismas métricas y las 150 ejecuciones para los tres escenarios.

Conclusiones

1. La base de datos contiene 650 registros, 30 variables predictoras y una distribución desbalanceada entre las clases negativa y positiva.
2. En la sintonización de FSCNCA, el accuracy máximo observado fue 68,37 %, alcanzado con lambda igual a 0,01, 1 y 10.
3. En la evaluación individual de Forward Selection, la configuración de 12 variables alcanzó un accuracy de 77,55 % y una sensibilidad de 16 %.
4. En el resumen de las 150 ejecuciones disponibles, FSCNCA obtuvo un accuracy promedio de 63,97 %, mientras que Forward Selection obtuvo 42,73 %. Forward Selection presentó mayor sensibilidad promedio.
5. La comparación definitiva requiere completar la evaluación de referencia con todas las variables y confirmar las métricas de entrenamiento, validación y prueba para los tres escenarios.

6. Las conclusiones sobre la separación de clases mediante PCA deben redactarse después de incorporar y analizar las tres proyecciones y sus porcentajes de varianza explicada.